Explicación de Pesos

Tablas 7–13 del Documento Comparativa

Synthetic Difference-in-Differences (SDID)
vs Synthetic Control (SC) vs Difference-in-Differences (DiD)

Dataset: Cigar (Baltagi, 2002) — 46 estados EE.UU., 1963–1992

Outcome: Ventas de cigarrillos (paquetes per cápita)

Comparación: **Python** (`synthdid.py`) vs **Stata** (`sdid`)

Marzo 2026

Índice

1. Marco Conceptual: ¿Qué son los pesos $\hat{\omega}$ y $\hat{\lambda}$? **2**

2. Tabla 7 — Diferencia máxima entre pesos Python y Stata **3**

3. Tablas 8, 9 y 10 — Pesos temporales $\hat{\lambda}$ por método **4**
3.1. Tabla 8 — $\hat{\lambda}$ SDID 4
3.2. Tabla 9 — $\hat{\lambda}$ SC 5
3.3. Tabla 10 — $\hat{\lambda}$ DiD 5

4. Tablas 11, 12 y 13 — Pesos de unidades $\hat{\omega}$ por método **7**
4.1. Tabla 11 — $\hat{\omega}$ SDID 7
4.2. Tabla 12 — $\hat{\omega}$ SC 8
4.3. Tabla 13 — $\hat{\omega}$ DiD 8

5. Comparación cruzada de los tres métodos **10**
5.1. Resumen de pesos $\hat{\lambda}$ 10
5.2. Resumen de pesos $\hat{\omega}$ 10

1. Marco Conceptual: ¿Qué son los pesos $\hat{\omega}$ y $\hat{\lambda}$?

El estimador SDID (y sus variantes SC y DiD) construye un **contrafactual sintético** combinando unidades de control y periodos de tiempo mediante dos tipos de pesos:

Pesos de unidades de control $\hat{\omega}_i$ (quién)

Determinan **qué estados de control** contribuyen al contrafactual y en qué proporción. Un $\hat{\omega}_i$ alto significa que el estado i es muy parecido al grupo tratado en el período pre-tratamiento. Se exige que $\hat{\omega}_i \geq 0$ y $\sum_i \hat{\omega}_i = 1$.

Pesos temporales $\hat{\lambda}_t$ (cuándo)

Determinan **qué años pre-tratamiento** son más informativos para predecir el nivel contrafactual justo antes del tratamiento. Se exige que $\hat{\lambda}_t \geq 0$ y $\sum_t \hat{\lambda}_t = 1$. Solo existen en SDID y DiD (en SC son todos cero).

Cada método los obtiene de forma diferente:

	SDID	**SC**	**DiD**
$\hat{\omega}_i$	Optimización regularizada	Optimización (sin regularizar)	Uniforme $1/N_0$
$\hat{\lambda}_t$	Optimización regularizada	0 para todo t	Uniforme $1/T_0$

En el dataset Cigar hay **38 estados de control** ($N_0 = 38$) y **7 cohortes** de adopción: 1975, 1976, 1978, 1979, 1981, 1983 y 1986. Cada cohorte tiene su propia estimación de $\hat{\omega}$ y $\hat{\lambda}$ de forma independiente.

2. Tabla 7 — Diferencia máxima entre pesos Python y Stata

Cuadro 1: Diferencia máxima absoluta entre pesos **Python** y **Stata**

Método	$\text{máx}\,\lvert\hat{\omega}^{\text{Py}} - \hat{\omega}^{\text{Stata}}\rvert$	$\text{máx}\,\lvert\hat{\lambda}^{\text{Py}} - \hat{\lambda}^{\text{Stata}}\rvert$
SDID	$4{,}8 \times 10^{-8}$	$4{,}0 \times 10^{-8}$
SC	$5{,}0 \times 10^{-8}$	0 (exacto)
DiD	$1{,}1 \times 10^{-8}$	$4{,}4 \times 10^{-8}$

¿Qué mide esta tabla?

Esta tabla es el **resumen ejecutivo** de toda la comparación de pesos. Para cada método, reporta la diferencia absoluta máxima entre los pesos calculados por **Python** y los calculados por **Stata**, tomando el máximo sobre todas las cohortes y todas las unidades (o años).

Interpretación

Las diferencias son del orden de 10^{-8}, es decir, 0,00000005. Esto es **ruido numérico puro**, no una diferencia real de implementación.
¿Por qué existen estas diferencias? Ambos paquetes usan el algoritmo Frank-Wolfe para resolver la optimización, pero lo implementan en entornos distintos:

- **Python**: NumPy (Python), aritmética en C/Fortran con IEEE 754 double precision
- **Stata**: Mata (Stata), su propio motor de álgebra matricial

Pequeñas diferencias en el orden de las operaciones flotantes se acumulan iteración a iteración hasta producir discrepancias de $\sim 10^{-8}$.

Resultado clave

A **4 decimales**, los pesos son **idénticos** entre Python y Stata en los tres métodos y las siete cohortes. El máximo diferencial (5×10^{-8}) equivale a un error de 1 en la octava cifra decimal. Ambas implementaciones convergen al mismo óptimo matemático.
Nota especial SC: $\hat{\lambda}^{SC} = 0$ exactamente en ambos paquetes porque es un valor fijo por diseño, no un resultado numérico.

3. Tablas 8, 9 y 10 — Pesos temporales $\hat{\lambda}$ por método

3.1. Tabla 8 — $\hat{\lambda}$ SDID

Cuadro 2: Pesos temporales $\hat{\lambda}$ — SDID. Python = Stata a 4 decimales.

Año	1975	1976	1978	1979	1981	1983	1986
1963	0	0.0011	0.2195	0.1566	0.0641	0.0711	0
1965	0.1382	0.1854	0	0	0	0	0
1969	0	0.0034	0	0	0	0	0
1974	**0.8618**	0	0	0	0	0	0
1975	–	**0.8100**	0	0	0	0	0
1977	–	–	**0.7805**	0	0	0	0
1978	–	–	–	**0.8434**	0	0	0
1980	–	–	–	–	**0.9359**	0	0
1982	–	–	–	–	–	**0.9289**	0
1985	–	–	–	–	–	–	**1.0000**

Los años no mostrados tienen $\hat{\lambda}_t = 0$. "–" indica año post-tratamiento para esa cohorte.

¿Qué significa?

El SDID asigna más peso a los años pre-tratamiento que mejor predicen el nivel de la variable de resultado justo *antes* de la intervención. El patrón es muy claro:

- **El año inmediatamente anterior al tratamiento recibe casi todo el peso** (resaltado en amarillo), entre 0.76 y 1.00.
- Los demás años reciben pesos pequeños o cero.

Interpretación

¿Por qué el último año pre-tratamiento domina?
El algoritmo SDID busca los años donde el control sintético (construido con $\hat{\omega}$) se parece más al grupo tratado. El año más reciente antes del tratamiento tiende a ser el mejor predictor del nivel contrafactual "en ausencia del tratamiento", porque captura las tendencias de corto plazo.

Cohorte 1986 es el caso extremo: $\hat{\lambda}_{1985} = 1{,}0$. Todo el peso recae en el año 1985, el único que predice perfectamente el nivel de ventas de cigarrillos que habría tenido el estado 42 si no hubiera subido el impuesto en 1986.

Cohorte 1963 vs 1965: Algunas cohortes (1976, 1978, 1979...) tienen pesos residuales en 1963 o 1965. Esto ocurre cuando hubo una tendencia especial en esos años que el algoritmo considera relevante para el matching de largo plazo.

En los **gráficos de trayectorias**, el área verde sombreada *es* este $\hat{\lambda}$: las barras más altas corresponden a los años con más peso, mostrando visualmente qué parte del pre-período "importa" más.

3.2. Tabla 9 — $\hat{\lambda}$ SC

Cuadro 3: Pesos temporales $\hat{\lambda}$ — SC. Python = Stata a 4 decimales.

Año	1975	1976	1978	1979	1981	1983	1986
SC: $\hat{\lambda}_t = 0\ \forall t$ *(sin ponderación temporal pre-período).*							

¿Qué significa?

El Synthetic Control puro **no usa pesos temporales**. Fija $\hat{\lambda}_t = 0$ para todos los años pre-tratamiento por diseño. El matching se hace únicamente a través de los pesos de unidades $\hat{\omega}_i$.

Interpretación

En el SC clásico (Abadie et al., 2010), el objetivo es encontrar una combinación de controles que replique el *nivel promedio* del outcome pre-tratamiento (y a veces covariables adicionales). No existe una selección de qué años importan más: todos los periodos pre-tratamiento cuentan por igual *en la restricción de matching*, aunque el promedio no se construye con pesos lambda explícitos.

En términos de los gráficos de trayectorias: la cohorte SC **no muestra área verde sombreada** porque $\hat{\lambda}_t = 0\ \forall t$.

3.3. Tabla 10 — $\hat{\lambda}$ DiD

Cuadro 4: Pesos temporales $\hat{\lambda}$ — DiD. Python = Stata a 4 decimales.

Año	1975	1976	1978	1979	1981	1983	1986
1963	0.0833	0.0769	0.0667	0.0625	0.0556	0.0500	0.0435
1964	0.0833	0.0769	0.0667	0.0625	0.0556	0.0500	0.0435
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮
1974	0.0833	0.0769	0.0667	0.0625	0.0556	0.0500	0.0435
1975	–	0.0769	0.0667	0.0625	0.0556	0.0500	0.0435
⋮		⋮	⋮	⋮	⋮	⋮	⋮
1985	–	–	–	–	–	–	0.0435
T_0	12	13	15	16	18	20	23
$1/T_0$	0.0833	0.0769	0.0667	0.0625	0.0556	0.0500	0.0435

¿Qué significa?

El DiD asigna **peso uniforme** $\hat{\lambda}_t = 1/T_0$ a cada año pre-tratamiento. Cada cohorte tiene un valor distinto porque tiene distinto T_0:

- Cohorte 1975: $T_0 = 12$ años pre $\Rightarrow \hat{\lambda}_t = 1/12 \approx 0{,}0833$
- Cohorte 1986: $T_0 = 23$ años pre $\Rightarrow \hat{\lambda}_t = 1/23 \approx 0{,}0435$

Interpretación

El DiD **trata todos los años pasados como igualmente informativos**. Esto equivale a comparar diferencias en promedio pre vs promedio post, sin distinguir si 1963 o 1974 es

más relevante para predecir 1975.
Esta restricción es más fuerte que SDID (que concentra el peso en 1-2 años) y hace al DiD más sensible a tendencias pre-tratamiento no paralelas.

4. Tablas 11, 12 y 13 — Pesos de unidades $\hat{\omega}$ por método

4.1. Tabla 11 — $\hat{\omega}$ SDID

Cuadro 5: Pesos unitarios $\hat{\omega}$ — SDID. Python = Stata a 4 decimales. (Selección de estados)

Estado	1975	1976	1978	1979	1981	1983	1986
1	0.0385	0	0.0463	0.0084	0	0.0131	0.0352
5	0.0503	**0.1436**	0.0078	0	0.0979	0.0173	0.0082
8	0	0.0126	0	0.0291	**0.2680**	0.0520	0.0174
14	0.0387	**0.1770**	0.0041	0.0038	**0.1180**	0.0284	0.0308
18	0.0579	0	**0.1442**	0.0326	0	0.0062	0.0257
22	0.0296	0.0637	0.0035	0.0021	**0.2476**	0.0375	0.0238
31	0.0137	**0.2523**	0	0.0102	**0.1750**	0.0150	0.0134
36	0	**0.1110**	0	0.0298	0.0299	0.0527	0.0196
39	0.0305	**0.1293**	0.0095	0.0265	0.0068	0.0378	0.0464
46	0.0535	0	0.0752	0.0395	0	0.0085	0.0718
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮

En negrita: pesos $\geq 0{,}10$. *Total: 38 estados de control, todos con* $\hat{\omega}_i \geq 0$, $\sum = 1$.

¿Qué significa?

Los pesos $\hat{\omega}^{SDID}$ miden la importancia de cada estado de control en la construcción del contrafactual sintético. Sus características son:

1. **Difusos**: La mayoría de los 38 estados recibe algún peso positivo. Raramente un solo estado domina.
2. **Regularizados**: El SDID penaliza pesos extremos mediante el parámetro $\zeta_\omega = \eta \cdot \hat{\sigma}$, donde $\eta = (N_1 T_1)^{1/4}$. Esto evita el overfitting al pre-período.
3. **Varían por cohorte**: Cada cohorte tiene su propio grupo de controles más relevantes, porque el conjunto de tratados cambia.

Interpretación

Cohorte 1976 es notable: el estado 31 recibe $\hat{\omega}_{31} = 0{,}2523$ (el peso más alto del SDID en todo el documento). Esto indica que ese estado de control sigue una trayectoria de ventas de cigarrillos muy similar a los 2 estados tratados en 1976 (estados 9 y 40).

Cohorte 1981: Los estados 8 (0.2680) y 22 (0.2476) dominan, concentrando juntos el 51.6 % del peso. Esto sucede porque, para esa cohorte, esos dos estados son los mejores "gemelos" del estado tratado (7) en términos de tendencia pre-tratamiento de ventas.

Los estados con $\hat{\omega}_i = 0$ no contribuyen al contrafactual; el algoritmo los descartó porque sus trayectorias no aportan información adicional para el matching.

4.2. Tabla 12 — $\hat{\omega}$ SC

Cuadro 6: Pesos unitarios $\hat{\omega}$ — SC. Python = Stata a 4 decimales. (Selección de estados)

Estado	1975	1976	1978	1979	1981	1983	1986
4	0	0	0	**0.4494**	0	0	0.0162
5	0.1193	0	0	0	0	0	0
8	0	0.1676	0.0030	0	0.0435	0.0285	0
10	0.0302	0	0.0885	0	0	0.1354	0
14	0	**0.3841**	0	0	0	0	0
17	**0.3106**	0	0	0.0129	0	0	0
18	0.0480	0	**0.3175**	0.0156	0	0.0147	0.0002
22	0	0	0	0	**0.9188**	0.0026	0
30	0.0005	**0.3057**	0.0335	0.0448	0	0.0562	0.0036
33	0.0882	0	**0.3645**	0	0	0	0.0875
45	0.0001	0.0007	0.0077	0.0083	0	0.0051	**0.4037**
46	0.1933	0	0.1025	0.0474	0	0	**0.2015**
50	0	0	0	**0.2647**	0	**0.3445**	0
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮

En negrita: pesos $\geq 0{,}10$. *La mayoría de estados tienen* $\hat{\omega}_i = 0$.

¿Qué significa?

Los pesos $\hat{\omega}^{SC}$ son mucho más **dispersos** (sparse) que los del SDID:

1. **Alta concentración**: 1-4 estados reciben casi todo el peso por cohorte.
2. **Muchos ceros**: La mayoría de los 38 estados de control reciben $\hat{\omega}_i = 0$.
3. **Sin regularización** (o mínima, $\zeta = 10^{-6}\hat{\sigma}$): el SC puede asignar pesos muy extremos si un estado replica bien el pre-período.

Interpretación

Casos extremos:

- **Cohorte 1981**: Estado 22 recibe $\hat{\omega}_{22}^{SC} = 0{,}9188$. Un solo estado de control construye el 92 % del contrafactual. Esto indica que el estado 22 tiene una trayectoria pre-tratamiento *casi idéntica* al estado tratado 7, pero también es señal de potencial **overfitting**: el contrafactual "memoriza" el pre-período en lugar de generalizar.
- **Cohorte 1979**: Estado 4 recibe 0.4494, Estado 50 recibe 0.2647. Dos estados concentran el 71 % del peso.

Comparación con SDID: El SDID distribuye el peso entre muchos más estados, lo que le da mayor **estabilidad** ante posibles outliers. El SC puede dar estimaciones más precisas si el matching es perfecto, pero más sensibles si uno de los estados "dominantes" tiene un shock idiosincrásico.

4.3. Tabla 13 — $\hat{\omega}$ DiD

Cuadro 7: Pesos unitarios $\hat{\omega}$ — DiD. Python = Stata a 4 decimales.

Estado	1975	1976	1978	1979	1981	1983	1986
DiD: los 38 estados de control reciben peso uniforme $\hat{\omega}_i = 1/38 \approx 0{,}0263$ *en todas las cohortes.*							

¿Qué significa?

El DiD asigna el mismo peso $1/38 \approx 0{,}0263$ a **todos** los estados de control, independientemente de si su trayectoria pre-tratamiento se parece o no a la del tratado.

Interpretación

El DiD es el estimador menos flexible de los tres. No intenta encontrar los controles más parecidos: simplemente promedia a todos por igual. Esto equivale a comparar la diferencia en medias:

$$\widehat{ATT}^{DiD} = \underbrace{\bar{Y}_{\text{tratados, post}}}_{\text{promedio post trat.}} - \underbrace{\bar{Y}_{\text{tratados, pre}}}_{\text{promedio pre trat.}} - \left(\underbrace{\bar{Y}_{\text{controles, post}}}_{\text{promedio post control}} - \underbrace{\bar{Y}_{\text{controles, pre}}}_{\text{promedio pre control}} \right)$$

En el documento, el ATT DiD es $-19{,}48$ vs SDID $-13{,}85$. La diferencia ($\approx 5{,}6$ paquetes) refleja que el grupo de controles promedio *no* es un buen contrafactual para los estados tratados: los estados con alza fiscal tenían tendencias pre-tratamiento distintas al promedio nacional, lo que el SDID y SC corrigen mediante sus pesos óptimos.

5. Comparación cruzada de los tres métodos

5.1. Resumen de pesos $\hat{\lambda}$

Cuadro 8: Características de $\hat{\lambda}$ por método

Característica	SDID	SC	DiD
Optimización	Sí (regularizada)	No (fijado en 0)	No (uniforme)
Años con peso > 0	1–3 por cohorte	Ninguno	Todos los pre-período
Concentración	Alta (1 año domina)	—	Nula (uniforme)
Peso máximo típico	0.86–1.00	0	$1/T_0$

5.2. Resumen de pesos $\hat{\omega}$

Cuadro 9: Características de $\hat{\omega}$ por método

Característica	SDID	SC	DiD
Optimización	Sí (regularizada)	Sí (sin regularizar)	No (uniforme)
Estados con peso > 0	$\sim$25–35 de 38	3–8 de 38	Los 38
Concentración	Baja-moderada	Alta	Nula
Peso máximo típico	0.10–0.27	0.38–0.92	0.0263
Riesgo overfitting	Bajo	Alto	Muy bajo

Resultado clave

Los tres métodos producen ATT **idénticos a 4 decimales** entre Python y Stata, confirmado por las Tablas 7–13. Las diferencias residuales de $\sim 10^{-8}$ en los pesos son acumulaciones de redondeo de punto flotante en el algoritmo Frank-Wolfe, sin ningún efecto práctico sobre las estimaciones.

La elección entre SDID, SC y DiD no afecta la *equivalencia numérica* entre implementaciones, pero sí afecta la *estimación del ATT*: el DiD sobreestima el efecto ($-19{,}48$ vs $-13{,}85$ SDID) porque usa controles no comparables; el SC produce $-13{,}37$, muy cercano al SDID gracias a sus pesos óptimos, pero con mayor riesgo de overfitting por su alta concentración.

Referencias

[1] Arkhangelsky, D., Athey, S., Hirshberg, D.A., Imbens, G.W. & Wager, S. (2021). *Synthetic Difference-in-Differences. American Economic Review*, 111(12), 4088–4118.

[2] Abadie, A., Diamond, A. & Hainmueller, J. (2010). *Synthetic Control Methods for Comparative Case Studies: Estimating the Effect of California's Tobacco Control Program. Journal of the American Statistical Association*, 105(490), 493–505.

[3] Pailañir, D. & Clarke, D. (2022). *SDID: Stata module to implement Synthetic Difference-in-Differences.* Statistical Software Components S459058, Boston College.

[4] Baltagi, B.H. (2002). *Econometrics* (3rd ed.). Springer.